Puntos automáticos DINOv3 para SAM 2.1 en segmentación de agua superficial Sentinel-2 (Sen1Floods11): informe E3

E. Villarreal[1] y R. Chávez[1]
[1]PUCP, Ingeniería Informática, Deep Learning 1INF52 (2026-2)
Repositorio: github.com/roberto-chavez/auto-prompt-sam2
Versión previa al workshop; la revisión con su retroalimentación está **pendiente de confirmación**

Abstract

Estudiamos cuánto cambia la calidad de SAM 2.1 al sustituir puntos simulados desde etiquetas por puntos automáticos derivados de DINOv3 para segmentar agua superficial (incluida agua permanente) en Sentinel-2. Con presupuesto nominal igualado (3+/3− por componente) y decoder congelado, el IoU de agua en validación pasa de 0.154 (referencia asistida) a 0.299 (*official*) y de 0.152 a 0.317 (*leave_paraguay_out*); la hipótesis previa de que los puntos automáticos quedarían por debajo de la referencia asistida queda refutada en validación. Los totales reales de puntos de ambos brazos no se han verificado. Entrenar solo el mask decoder eleva el IoU a 0.484/0.506, un factor distinto del tipo de prompt. Ningún conjunto reservado se ha abierto: no hay evidencia de transferencia geográfica.

1 Problema y pregunta

SAM 2.1 [1] segmenta a partir de prompts, pero las imágenes satelitales carecen de un usuario que los coloque. La pregunta del proyecto es: *¿cuánto cambia la calidad al sustituir puntos simulados desde etiquetas por puntos automáticos derivados de DINOv3 [2]?* La tarea es segmentar **agua superficial**, incluida el agua permanente; no se afirma detectar solo inundaciones recientes.

2 Datos, particiones y preprocesamiento

Usamos Sen1Floods11 [6] (chips Sentinel-2 con etiqueta manual). Dos regímenes: *official* (252 train / 89 val) y *leave_paraguay_out* (213/75), con Bolivia y Paraguay reservados sin abrir. Las configuraciones se fijan con train/val; los reservados no se han tocado. El flujo automático consume solo imagen, características y validez; la sonda de agua se entrena con etiquetas de train (no es un sistema libre de etiquetas). Métrica principal: IoU de agua acumulado (pooled); precisión, recall y Dice la explican.

Protocolo y comparabilidad (antecedente)

Table 1: Diferencias que afectan la interpretación de cada fila.

Fila	Origen de componentes	Puntos	Decoder
Etapa 3	etiqueta (real)	1+/1−	congelado
Etapa 5	predicción DINOv3	≤3+/3−	congelado
Malla	SAM 32×32 + DINOv3	automático	congelado
Etapa 6	predicción DINOv3	≤3+/3−	entrenado

El evaluador (IoU acumulado sobre píxeles válidos), el preprocesamiento y las particiones son los mismos en todas las filas; lo que cambia es la columna anterior. Por eso etapa 3 vs. etapa 5 mezcla dos factores (origen de componentes y presupuesto) y etapa 5 vs. etapa 6 cambia el decoder. Cada factor debe aislarse con la matriz de la etapa 7 (A1: fuente de prompt con presupuesto 3+/3− igualado; A2: barridos de k; A3: congelado vs. ajustado con la misma ruta).

Table 2: Tamaño de las particiones y objetivos de la sonda (etapa 5).

Régimen	train	val	píx agua (train)	píx no agua
official	252	89	19 538	192 017
leave_paraguay_out	213	75	16 660	158 771

Los píxeles de la tabla son celdas de la rejilla de características 32×32; 46 493 (official) y 42 681 (excluido) celdas se ignoran por validez. Cada régimen tiene su propio escalador y sonda, de modo que ninguna estadística de validación ni de Paraguay reservado entra en el ajuste.

3 Línea base y teardown

Modelo `facebook/sam2.1-hiera-tiny` (Apache-2.0): 38 962 498 parámetros (encoder de imagen 27.2 M; mask decoder 4 215 109; encoder de prompts 6 220; memoria y proyecciones 7.5 M) y 296.05 GFLOPs contados (parcial). Con 1+/1− pun-

tos tomados de etiquetas y decoder congelado, el IoU en validación es 0.158 (official): recall alto (0.894) y precisión baja (0.161), es decir, sobre-segmentación.

Table 3: Teardown de SAM 2.1 hiera-tiny (conteos reproducibles con `scripts/teardown_architecture_counts.py`).

Bloque	Parámetros
Encoder de imagen (Hiera)	27 219 136
Mask decoder	4 215 109
Memoria y proyecciones	7 520 736
Encoder de prompts	6 220
Residual	1 297
Total	38 962 498

El mask decoder es solo el 10.8 % de los parámetros (4 215 109 de 38 962 498); por eso es el candidato económico para adaptar sin tocar el encoder, que concentra el 69.9 %. El módulo de memoria no interviene en la inferencia sobre una imagen.

4 Método automático e intervención del decoder

Puntos. Características DINOv3 ViT-L/16 SAT-493M congeladas ($32\times32\times1024$) → sonda logística supervisada → mapa de probabilidad → componentes y hasta 3+/3− puntos por componente → SAM (máscara de mayor IoU predicho) → unión. Se comparó también una malla de SAM puntuada con DINOv3. La configuración elegida (C=0.1, umbral 0.7) deja 28/89 y 24/75 chips sin componentes (máscara vacía).
Decoder. Se entrena solo el mask decoder (4 215 109 parámetros; BCE+Dice sobre píxeles válidos; AdamW 10^{-5}, 10 épocas, FP32), con encoder de imagen y de prompts congelados.

5 Resultados (solo validación)

Puntos simulados vs. automáticos (decoder congelado). Antecedente descriptivo (etapas 3 y 5): los puntos automáticos duplican el IoU en ambos regímenes, a costa de menos recall y más precisión. *Salvedad que afecta la interpretación:* los puntos de etiqueta son 1+/1− por componente real, los automáticos hasta 3+/3− por componente predicho (presupuestos reales 1 204+/2 055− en official). No es una comparación con presupuesto igualado. La comparación con referencia asistida igualada se ejecutó después, en la etapa 7 (sección siguiente).

Congelado vs. ajustado. Ajustar el decoder suma +18.5 pp (official) y +18.9 pp (excluido) respecto a la etapa 5, con una semilla; la mejor época y el umbral se eligieron en la misma validación. Es un efecto del decoder, no del prompt. En la intervención preliminar E2 (40 chips, puntos simulados, semilla 42) el IoU pasó de 0.170 a 0.308 en la época 1 y cayó a 0.150 en la época 4: el ajuste es inestable.
Transferencia. *No evaluada.* La diferencia entre regímenes ocurre en poblaciones de validación distintas y no prueba transferencia geográfica.

Table 4: IoU de agua en validación (cifras recalculadas desde las salidas originales con `scripts/e3_collect_results.py`).

Fila	IoU	Prec.	Rec.	Dice
official (89 chips)				
Etiq. 1+/1−, congelado	.158	.161	.894	.273
DINOv3 ≤3+/3−, congelado	.299	.327	.774	.460
Malla SAM+DINOv3, congelado	.179	.922	.181	.303
DINOv3, decoder entrenado (ép. 10)	.484	.688	.620	.652
leave_paraguay_out (75 chips)				
Etiq. 1+/1−, congelado	.168	.169	.969	.288
DINOv3 ≤3+/3−, congelado	.317	.354	.750	.481
Malla SAM+DINOv3, congelado	.209	.906	.213	.345
DINOv3, decoder entrenado (ép. 8)	.506	.738	.617	.672

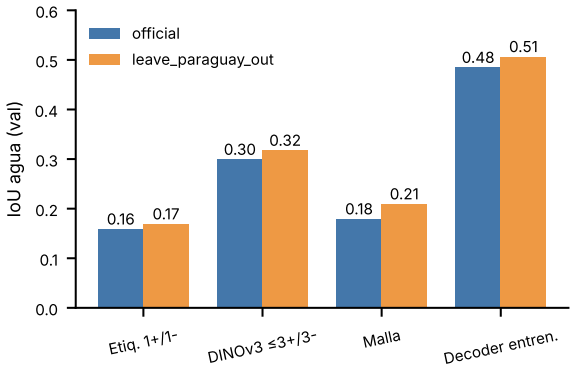


Figure 1: IoU de agua en validación por fila (mismos datos que la tabla de resultados). Las filas no son todas comparables entre sí (ver texto).

6 Etapa 7 ejecutada: ablaciones A1–A3

La etapa 7 se ejecutó en Colab (notebook notebook 07 ejecutado, commit `ebde34e`) sobre las 13 filas y

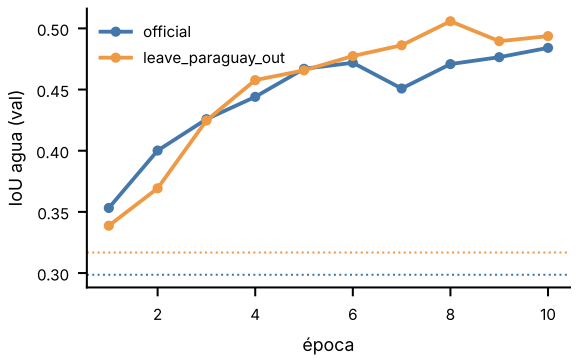


Figure 2: IoU de validación por época del decoder entrenado (etapa 6); las líneas punteadas son la etapa 5 congelada.

Table 5: Etapa 6: métricas de validación por época (de `curves.json`).

Ép.	IoU off.	Dice off.	IoU excl.	Dice excl.
1	0.353	0.522	0.339	0.506
2	0.400	0.572	0.369	0.539
3	0.426	0.597	0.425	0.596
4	0.444	0.615	0.458	0.628
5	0.467	0.637	0.466	0.635
6	0.472	0.641	0.477	0.646
7	0.451	0.621	0.486	0.654
8	0.471	0.640	0.506	0.672
9	0.476	0.645	0.490	0.657
10	0.484	0.652	0.494	0.661

las validaciones de ambos regímenes (89 y 75 chips), sin entrenar ni recalibrar (se reutilizan sonda, umbrales y mejor época de las etapas 5–6) y sin abrir conjuntos reservados. Los valores de control coinciden con la salida del notebook: official 0.1540 / 0.2986 / 0.4841 y excluido 0.1515 / 0.3168 / 0.5058 (asistido igualado / automático / decoder ajustado). Además, la etapa 7 reproduce *exactamente* las cifras de las etapas 3 y 5 (fila histórica 0.1580/0.1684; puntos 0.2986/0.3168; malla 0.1785/0.2088), lo que respalda la consistencia de la re-ejecución. **A1: qué cambia.**

Table 6: A1 (etapa 7, decoder congelado, val.): IoU de agua (prec., recall).

Fila	official (89)	excluido (75)
DINOv3 $\leq$3+/3− (auto)	.299 (.327, .774)	.317 (.354, .750)
Etiq. 3+/3− (asistida igualada)	.154 (.155, .960)	.152 (.152, .974)
Etiq. 1+/1− (histórica)	.158 (.161, .894)	.168 (.169, .969)
Malla SAM+DINOv3	.179 (.922, .181)	.209 (.906, .213)
Caja completa (control)	.098 (.099, .872)	.100 (.102, .887)

Solo la fuente del prompt (decoder, preprocesamiento, evaluador y chips iguales). La referencia asistida iguala el presupuesto *nominal* (3+/3− por componente), pero sus componentes provienen de las etiquetas y los automáticos de la sonda, y el presupuesto es *por componente, no por chip*. Por tanto **no afirmamos que ambos brazos usaran el mismo total de puntos**: el total real solo se conoce para el brazo automático de la etapa 5 (1 204+/2 055− en official) y los conteos reales de la referencia asistida están en los `result_*.json` de la evidencia, pendientes de totalizar (`e3_point_budget.py`). Resultado observado: los puntos automáticos superan a la referencia asistida igualada en +14.5 pp (official) y +16.5 pp (excluido); la referencia tiene recall 0.96–0.97 pero precisión 0.15, es decir, sobre-segmenta. Pasar de 1+/1− a 3+/3− no mejoró la referencia (0.158→0.154; 0.168→0.152), por lo que la diferencia no se explica por el número nominal de puntos. Por qué los puntos automáticos se comportan mejor es una *hipótesis* sin verificar (p. ej., se ubican en zonas de alta probabilidad de agua); no se analizaron ejemplos. **A2.** Con

Table 7: A2 (etapa 7): IoU de agua al variar k^+ (con k^-=3) o k^- (con k^+=3); k es un tope por componente.

Barrido	k	official	excluido
k^+	1	.270	.293
	3*	.299	.317
	5	.310	.327
	10	.315	.334
k^-	0	.283	.283
	1	.307	.312
	3*	.299	.317
	5	.313	.320

* configuración fijada de la etapa 5 (fila A1 automática).

el decoder congelado, más positivos mejoran el IoU con rendimientos decrecientes (official: .270, .299, .310, .315 para k^+=1, 3, 5, 10; excluido: .293, .317, .327, .334); en excluido no se satura a k^+=10. Más negativos suben la precisión y bajan el recall (official: precisión .293 → .346 y recall .898 → .765 de k^-=0 a 5); el IoU crece de forma monótona en excluido, pero no en official (k^-=1: .307 > k^-=3: .299). Los k son topes: los puntos efectivos pueden ser menores (déficits permitidos). **A3.** Congelado vs. ajustado con la misma ruta y los mismos puntos: +18.5 pp (official, .299→.484) y +18.9 pp (excluido, .317→.506); la fila ajustada reutiliza el mejor checkpoint de la etapa 6, elegido en esta misma validación (estimación optimista). La selección de la etapa 7 fue `a3_tuned` en ambos regímenes.

Efecto sobre la hipótesis original. H1 (WAIMLAP) predecía IoU de puntos DINOv3 *menor* que la referencia asistida y mayor que la malla. La segunda parte se cumple (malla .179/.209), la primera queda **refutada** en validación con esta referencia asistida:

los puntos automáticos la superan. Esto no significa que las etiquetas sean inútiles: la sonda se entrena con etiquetas de train y la referencia usa un procedimiento fijo de puntos, no un límite superior. H2 se cumple en parte (rendimientos decrecientes en k^+; k^- reduce falsos positivos con costo en recall). H3 (ajuste mejora más lo visto que Bolivia) **no puede evaluarse** sin la etapa 8: aquí solo se mide la mejora en validación.

Auditoría. El JSON `revision_stage7_*.json` (Drive) indica, para ambos regímenes, estado "consistencia portátil aprobada, no cierre de etapa", 13 filas, sin fallos, 1 157 y 975 máscaras de validación auditadas de forma independiente y `reserved_access` vacío. Siguen pendientes la revisión humana y el *recover* offline en otro runtime de Colab; por eso `stage8_authorized=false`.

7 Análisis de fallos y limitaciones

Table 8: Cobertura de prompts (etapas 5–6, evidencia del repositorio).

	official	excluido
Chips val con prompts	61/89	51/75
Chips val sin componentes (etapa 5)	28/89	24/75
Train contribuyentes (etapa 6)	161/252	139/213
Train sin componentes	90	74

Observado: la mediana de IoU por chip con puntos automáticos es baja (0.113/0.140) y la malla alcanza mediana 0; la etapa 7 se ejecutó con un intento previo fallido (`Prior implementation changed: configs/baseline.yaml`, visible en la salida del notebook) antes de las ejecuciones guardadas; el decoder entrenado tiene cobertura parcial (61/89 chips de validación con prompts en official, el resto queda vacío); el régimen excluido decae tras la época 8 (0.490, 0.494 en ép. 9–10). *Hipótesis, no verificadas:* sombras, nubes o terreno oscuro como falsos positivos; el umbral alto de la sonda como causa de chips vacíos. No se revisaron ejemplos visuales en esta entrega. Limitaciones: una sola semilla, validación reutilizada para seleccionar, sin reservados, sin IC, solo SAM tiny y etapas 7–9 del plan inicial sin ejecutar.

8 Procedimiento de reproducción

Las cifras de este informe se regeneran sin GPU con `python scripts/e3_collect_results.py`, que lee los JSON y el ZIP de evidencia del repositorio. Reejecutar los experimentos requiere Colab con GPU, los secretos de Hugging Face (`HF_TOKEN`, no versionado) y acceso aprobado al modelo DINOv3 gated; los notebooks 05–07 contienen las celdas en orden (preparar, reiniciar el entorno y recuperar). Las pruebas locales (111 casos, sin modelos) verifican contratos de código, no resultados científicos.

9 Trabajo pendiente y reproducción

Requisito pendiente: (i) totalizar los puntos reales de ambos brazos (`e3_point_budget.py`), completar la revisión humana y el *recover* offline de la etapa 7; (ii) tras fijar la configuración en validación, evaluar transferencia con Bolivia y/o Paraguay reservado; (iii) incorporar la retroalimentación del workshop (18–20 nov), **pendiente de confirmación**. **Limitación:** una semilla, sin intervalos de confianza. **Mejora opcional:** análisis visual de ejemplos de mejora y fallo, y SAM de mayor tamaño. Las cifras se regeneran con `python scripts/e3_collect_results.py`; las etapas 5 y 6 las ejecutó R. Chávez en Colab T4 (evidencia en `docs/project/evidence/`), y la base E2 es trabajo conjunto ya publicado.

10 Registro de decisiones y uso de IA

El cuaderno de decisiones (`docs/project/cuaderno_decisiones.md`) registra, para cada etapa, la hipótesis previa, la justificación, la configuración, las semillas, los resultados y los fallos. Semillas: 42 en E2; las etapas 5–6 usan las semillas fijadas en sus configuraciones (`configs/`). Fallos documentados: una descarga dañada del paquete de la etapa 5 (1 067 entradas ilegibles) sustituida y re-auditada; la sonda con C=1 balanceada no convergió y se excluyó por criterio previo. Asistencia de IA: implementación y auditoría en CPU (Codex y Claude) sin ejecutar modelos; la ejecución en Colab la hicieron los integrantes. Los resultados se leen contra las salidas originales y no se han interpretado como evidencia de generalización.

11 Conclusiones

Con decoder congelado, los prompts DINOv3 superan a la referencia asistida de etiquetas en validación (0.299 vs. 0.154 con 3+/3− nominal; 0.158 con 1+/1−), y refutan la hipótesis H1 previa. Entrenar el decoder es el mayor efecto observado (+18.5 pp). Con presupuesto nominal igualado, los puntos automáticos también superan a la referencia asistida (+14.5/+16.5 pp), de modo que la ventaja no se debe solo al número de puntos; falta verificar el total real de puntos y evaluar la transferencia (etapa 8, bloqueada).

12 Intervención E2 previa

Table 9: E2: 40 chips de validación, puntos simulados, semilla 42, official.

Brazo	IoU	Prec.	Rec.	Dice
Congelado	.170	.171	.964	.291
Ajustado, mejor ép. 1	.308	.399	.575	.471

La mejora de la mejor época proviene de menos falsos positivos (precisión .171 $\rightarrow$ .399) a costa de recall (.964 $\rightarrow$ .575); la última época (IoU .150) muestra que el criterio de parada importa. Este resultado usa un subconjunto de 40 chips y no es comparable de forma directa con las 89 imágenes de las etapas 5–6.

13 Estado de la demo, licencias y reproducibilidad

La demo (Gradio) tiene pruebas locales de interfaz; **la carga de pesos reales y la inferencia punta a punta no se verificaron en esta entrega** (sin GPU ni acceso a Hugging Face desde el entorno de trabajo). Plantilla: este PDF usa la clase `article` a dos columnas porque la clase oficial IEEEtran/LNCS no pudo obtenerse en el entorno; `informe_E3_IEEEtran.tex` es la misma fuente para IEEEtran (no compilada aquí). Licencias consultadas: SAM 2.1, Apache-2.0 (tarjeta del modelo); DINOv3, licencia propia de Meta (redistribución bajo el mismo acuerdo, aviso "Built with DINOv3", restricciones de uso) [5]; Sen1Floods11: la página del artículo no indica licencia y la aclaración del repositorio sigue **pendiente**. Pesos, datos y checkpoints no se versionan. Asistencia de IA: registrada en el cuaderno de decisiones.

References

[1] N. Ravi et al., "SAM 2: Segment Anything in Images and Videos," arXiv:2408.00714, 2024.

[2] O. Siméoni et al., "DINOv3," arXiv:2508.10104, 2025 (título y primer autor verificados en arxiv.org/abs/2508.10104).

[3] Meta AI, modelo `facebook/dinov3-vitl16-pretrain-sat493m` (Hugging Face, acceso restringido aprobado); la página del modelo no pudo abrirse desde el entorno de redacción, solo se verificó la licencia general.

[4] Meta AI, modelo `facebook/sam2.1-hiera-tiny` (Hugging Face; licencia Apache-2.0).

[5] Meta AI, DINOv3 License, ai.meta.com/resources/models-and-libraries/dinov3-license.

[6] D. Bonafilia, B. Tellman, T. Anderson, E. Issenberg, "Sen1Floods11: A Georeferenced Dataset to Train and Test Deep Learning Flood Algorithms for Sentinel-1," CVPR Workshops, pp. 210–211, 2020; datos en github.com/cloudtostreet/Sen1Floods11.